


Introducción a la Adquisición de Datos.

El proceso de transformar la
ambigüedad en estructura.



SYSTEM OBJECTIVES

Recolectar, filtrar y almacenar.

Garantizar la calidad de los datos desde su origen para obtener resultados significativos y confiables.



Toma de decisiones informada.

(Precisión basada en hechos sobre suposición)



Automatización y predicciones.


(Alimentación de modelos de machine learning)



Optimización de recursos.


(Identificación de ineficiencias organizacionales)

El espectro de la estructura



Datos Estructurados

Tablas, SQL, Excel. Formato predefinido.



Datos Semi-estructurados

APIs, JSON, XML. Flexibles pero organizados.



Datos No Estructurados

Redes sociales, video, fotos, emails. Requieren herramientas especializadas.


Fuentes de extracción.



AUTHENTICATION PROTOCOLS

Las puertas de acceso a los datos.

Muchas interfaces (APIs) requieren credenciales de seguridad para permitir la extracción.



Códigos de Estado HTTP.


200		OK. Resultado devuelto exitosamente.
301		Redirección a un punto final diferente.
400		Bad Request. Solicitud incorrecta.
403		Prohibido. Acceso denegado al recurso.
404		Not Found. Recurso no encontrado.
503		Unavailable. Servidor no listo para manejar la solicitud.

AUTOMATED EXTRACTION

El Agente Activo: Web Scraping.

La técnica para extraer datos directamente del HTML cuando no hay una API disponible. Transforma contenido web en formatos utilizables.

⚠ **Atención:** Es fundamental respetar los términos de uso y no sobrecargar servidores.



[BeautifulSoup]

[Scrapy]

[Selenium]

Preservación del formato: Pickle.

STATE SERIALIZATION



Estructura de Datos Compleja
(DataFrames, Listas, Modelos
Entrenados)



Serialización (Python)



Archivo Pickle

Evita reentrenamientos.
Ahorra tiempo y recursos.

Alternativas: Joblib, HDF5.

Arquitectura final de adquisición.

