

Análisis Multivariado Avanzado

De PCA a SVM y PLSR:
Arquitectura, Modelado
y Negocio


CODERHOUSE 4.0 | DATA & AI ENGINEERING



El terreno: La matriz multivariada

El análisis multivariado captura la variabilidad conjunta y modela interacciones complejas que el análisis bivariado ignora.

Desde la ingeniería, todo comienza con la abstracción matemática de los datos: **la matriz X**.



Momentos de la Clase:


Para recordar La Regla de Oro Irrompible

La estandarización previa (ej. **StandardScaler**) es obligatoria en el análisis multivariado.

Las técnicas operan mediante transformaciones lineales y optimización de funciones objetivo (varianza o distancia). Sin estandarización, las variables con mayor magnitud dominarán matemáticamente los cálculos, destruyendo los patrones reales.

Exploración y Reducción: PCA

El Análisis de Componentes Principales (PCA) busca proyecciones ortogonales que maximicen la varianza interna de X, reduciendo el ruido.



Paso 1: Matriz estandarizada (X_scaled)

Paso 2: Matriz de covarianza → `np.cov(X_scaled.T)`

Paso 3: Eigen-descomposición → Eigenvalores y Eigenvectores

Paso 4: Biplot (Loadings)

Coder Tips

PCA como monitor en producción


Los componentes principales no solo sirven para entrenar más rápido. En etapa de inferencia (producción), debes **evaluar y monitorear la varianza explicada** por los componentes.

Una caída drástica en la varianza retenida es un indicador matemático directo de Data Drift (deriva de datos).

Regresión Multivariada: Introduciendo Y con PLSR


Mientras que PCA ignora la variable objetivo Y, **PLSR** (Partial Least Squares Regression) **proyecta simultáneamente X e Y** a un nuevo espacio latente.

PCA



PLSR

$$Y = XB + E$$



Deflactar (Residualizar): PLSR extrae componentes iterativamente y sustrae la varianza ya explicada antes de buscar el siguiente componente.

Diagnóstico de Modelos: PCR vs PLSR

¿Por qué no simplemente aplicar PCA y luego **Regresión Lineal** (PCR)?

	PCR	PLSR
Objetivo	Maximiza varianza de X	Maximiza covarianza X-Y
Eficiencia	Requiere más componentes	Más eficiente (menos componentes) 
Rendimiento	Arriesga perder información útil para Y	Superior con alta correlación X-Y 
Caso Ideal	Multicolinealidad sin respuesta definida	Quimiometría, múltiples respuestas (Y) altamente correlacionadas

El límite de la linealidad: SVM y el Kernel Trick

Cuando las relaciones superan la capacidad de los espacios latentes lineales, las Máquinas de Vectores de Soporte proyectan los datos hacia dimensiones superiores.

Fórmula Dual

El Truco:

$$\max_{\alpha} \sum \alpha_i - \frac{1}{2} \sum \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$


$K(x_i, x_j)$ permite calcular el producto punto en alta dimensión sin transformar explícitamente los datos.



Tipos de Kernel: Lineal (textos), Polinómico, y **RBF/Gaussiano** (por defecto para fronteras caóticas).

Estrategias para Multi-Clase y Multi-Output

SVM es inherentemente binario. Para predecir variables complejas, la arquitectura subyacente debe mutar.



ATENCIÓN: El **MultiOutputRegressor** asume que las Y son independientes. Si hay correlación, **PLSR** o **Redes Neuronales** son matemáticamente superiores.

El veredicto arquitectónico: PLSR vs SVM

Selección de algoritmos basada en escalabilidad, interpretabilidad y topología.

	PLSR	SVM
Naturaleza	Lineal	Lineal o No lineal
Output Múltiple	Nativo, aprovecha correlaciones de Y 	Requiere wrappers, ignora correlación
Interpretabilidad	Alta: Loadings, VIP Scores	Baja: Caja negra en Kernels
Escalabilidad	Excelente, $O(n \cdot p \cdot k)$ 	Pobre en inferencia masiva, $O(n^2)$ a $O(n^3)$

#FindTheBug

Fugas de datos (Data Leakage)

El error más común en code reviews de Data Engineering.

MAL ❌

Aplicar `fit_transform` del `StandardScaler` o `PCA` a todo el dataset antes del split de Train/Test.

BIEN ✅

Ajustar (`fit`) solo en el set de Train mediante un Pipeline de `scikit-learn`.

Si transformas antes de dividir, la información del conjunto de Test “fuga” hacia el entrenamiento. Usa `Nested Cross-Validation` para ajustar hiperparámetros (`C`, `gamma`) sin optimismo de validación.

Síntesis y Comunicación Técnica

Construir el pipeline es solo la mitad del trabajo; validar y comunicar define el impacto en el negocio.

Visualización

Usa tablas para < 20 datos numéricos críticos. Para datos masivos: Heatmaps de correlación o correlación o Biplots.

Estándar APA 7

No digas 'P-value es bajo'.
Reporta: $t(48) = 2.34$,
 $p = .023$, 95% CI [0.12, 0.89].

Narrativa de Negocio

No digas "El kernel RBF convergió". Di "El algoritmo segmentó correctamente a los clientes premium, logrando un 90% de precisión en producción."

Glosario Técnico Clave

Conceptos fundamentales para tu toolkit de Machine Learning.



Varianza Explicada: Proporción de la señal original retenida por un hiperplano.



Deflactar: Sustraer varianza ya explicada en PLSR antes de buscar nuevos componentes.



Hiperparámetro C (SVM): Controla regularización. Valores altos = riesgo overfitting. Valores bajos = underfitting.



VIP (Variable Importance in Projection): Métrica de PLSR que consolida el peso de una variable original a través de todo el espacio latente.