

CLASE DE SÍNTESIS

Aprendizaje No Supervisado

Reducción de Dimensionalidad y
y Clustering.

El viaje de hoy



**El objetivo: transformar un mar de conceptos matemáticos en herramientas tangibles y listas para usar.*

La Maldición de la Dimensionalidad

El Caos

Más variables = Modelos lentos, pesados y propensos a memorizar ruido (overfitting).

La Solución

Dos pilares fundamentales del Machine Learning: Reducción (simplificar) y Clustering (encontrar tribus).





01

Reducción de Dimensionalidad (PCA)

Dos caminos para reducir: Selección vs. Extracción



Selección

Elegimos las variables originales más críticas (ej. solo 'Gasto Promedio').


Ventaja: Mantiene el 100% de la interpretabilidad directa.



Extracción (El reino de PCA)

Creamos variables sintéticas (Componentes) combinando las originales.

Ventaja: Perdemos interpretabilidad directa, pero comprimimos la información al máximo y eliminamos redundancia.



La Regla de Oro del PCA

El Análisis de Componentes Principales (PCA) transforma variables correlacionadas en ejes ortogonales independientes para capturar la mayor variabilidad posible.

¡ES OBLIGATORIO ESTANDARIZAR! Usá StandardScaler. Si no lo hacés, variables gigantes como 'Ingreso Anual' (\$100,000) dominarán matemáticamente a las pequeñas como 'Edad' (25) solo por su escala, destruyendo tu análisis.

02

Agrupación de Datos (Clustering)

K-Means: El estándar de la industria

Agrupar datos por similitud hacia un "centroide" calculando distancias euclidianas.

- **El Reto:** Tenés que definir a mano cuántos grupos (K) buscar. Sufre mucho con los outliers.
- **¿Cómo elegir K?:**
 - **Método del Codo:** Busca aplanar la curva de inercia.
 - **Silhouette Score:** Mide qué tan aislado está cada grupo.
 - **Criterio de Negocio:** Si la empresa solo puede manejar 3 perfiles de clientes, $K=3$ es la respuesta.



Cuando K-Means se queda corto...

K-Means

¿Pide definir K?: **SÍ**

¿Maneja
Ruido/Outliers?: **NO**

Mejor uso: Grupos
redondos, bien
separados y de
tamaño similar.

DBSCAN

¿Pide definir K?: **NO**

¿Maneja
Ruido/Outliers?: **SÍ**

Mejor uso: Formas
irregulares, pero con
densidad constante.

HDBSCAN

¿Pide definir K?: **NO**


¿Maneja
Ruido/Outliers?: **SÍ**

Mejor uso: Formas
súper complejas con
densidades muy
variables.

K-Means es hipersensible a outliers porque calcula promedios geométricos.

Para recordar

El Pipeline Analítico Ideal



Los algoritmos no viven en el vacío

Marketing

Segmentar clientes (ej. cazadores de ofertas vs. premium) para campañas hiper-personalizadas.

Ciberseguridad

Detectar fraudes al aislar transacciones que quedan como 'ruido' fuera de los grupos normales.

NLP / Textos

Agrupar miles de tickets de soporte técnico por similitud semántica.

IoT / Industria

Definir el 'funcionamiento normal' de sensores y lanzar alertas de anomalías.

Si te llevás solo tres cosas hoy...



- 1** **La Estandarización es Ley:** PCA y K-Means fallan y se rompen si no igualás la escala de los datos antes de entrenar.
- 2** **Reducción = Estabilidad:** PCA elimina redundancia y acelera los modelos al comprimir la señal original, previniendo el overfitting.
- 3** **El Contexto Manda:** La matemática calcula centroides y distancias, pero es tu Criterio de Negocio el que bautiza y le da valor real a los clústeres.

Actividad colaborativa

Breakout Rooms: ¡Manos al código!

Abran el notebook de la clase.

1. Apliquen StandardScaler sobre el Dataset de Clientes.
2. Corran PCA para comprimir la información.
3. Usen el Método del Codo y corran K-Means para encontrar a sus 'tribus' de usuarios.

¡Muchas gracias!

Felicidades por dominar el territorio del Aprendizaje No Supervisado. Nos vemos en la próxima clase.