Validación y Problemas en Machine Learning

Construyendo modelos que generalizan en el mundo real.



Gemini Notebook

¿Cuál es el verdadero objetivo de evaluar un modelo?

¿Qué son el Sesgo y la Varianza?

¿Cómo estructurar una validación correcta?

¿Cómo evitar la temida fuga de información (Data Leakage)?

Gemini Notebook

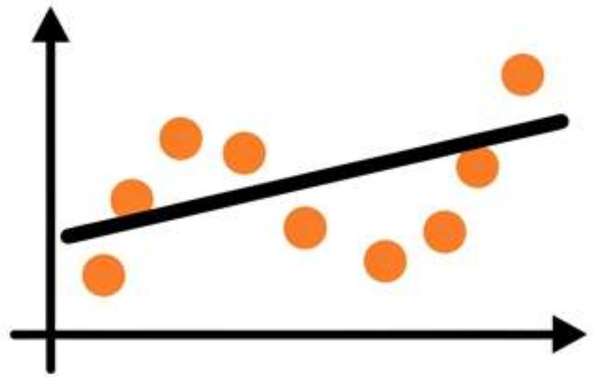
La Dialéctica de la Generalización

01

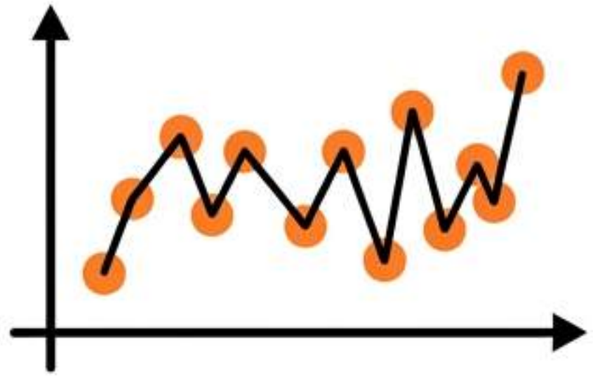
Gemini Notebook

Memorizar no es Aprender

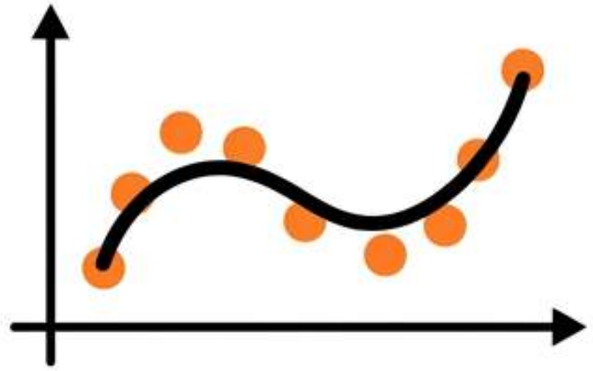
El objetivo prioritario de un modelo predictivo **no es memorizar** los datos de entrenamiento (fit), sino estimar y mejorar su **capacidad de generalización** frente a observaciones del mundo real no vistas.



Underfitting



Overfitting



Equilibrio (Generalización)

Gemini Notebook

Error Total del Modelo (Error Esperado)

Sesgo (Bias^2) - Error sistemático por supuestos demasiado restrictivos sobre la realidad.

Varianza – Inestabilidad (fotosensibilidad) al absorber ruido específico del dataset.

Error Irreducible (σ^2) - Ruido estocástico del proceso generador. El límite de precisión.

Gemini Notebook

El Equilibrio Tensión-Error (Trade-off)



ALTO SESGO (Bias)

- **Diagnóstico: El modelo es demasiado simple y rígido. Ignora patrones clave.**
- **Síntoma: Pobre desempeño incluso en entrenamiento.**
- **Resultado final: Underfitting (Subajuste).**



ALTA VARIANZA

- **Diagnóstico: El modelo es inestable. Aprende de memoria el ruido y correlaciones espurias.**
- **Síntoma: Excelente en entrenamiento, falla catastrófica en datos nuevos.**
- **Resultado final: Overfitting (Sobreajuste).**

Gemini Notebook

Para pensar

Si un modelo predictivo alcanza un **100% de precisión** exacto en sus datos de entrenamiento... ¿Deberíamos celebrar el éxito o preocuparnos inmediatamente?

Gemini Notebook

02

Estrategias y Esquemas de Validación

Gemini Notebook

Dataset Completo

Conjunto de Desarrollo (80%)

Utilizado para Cross-Validation y ajuste de hiperparámetros.

Test Set Final (20%)

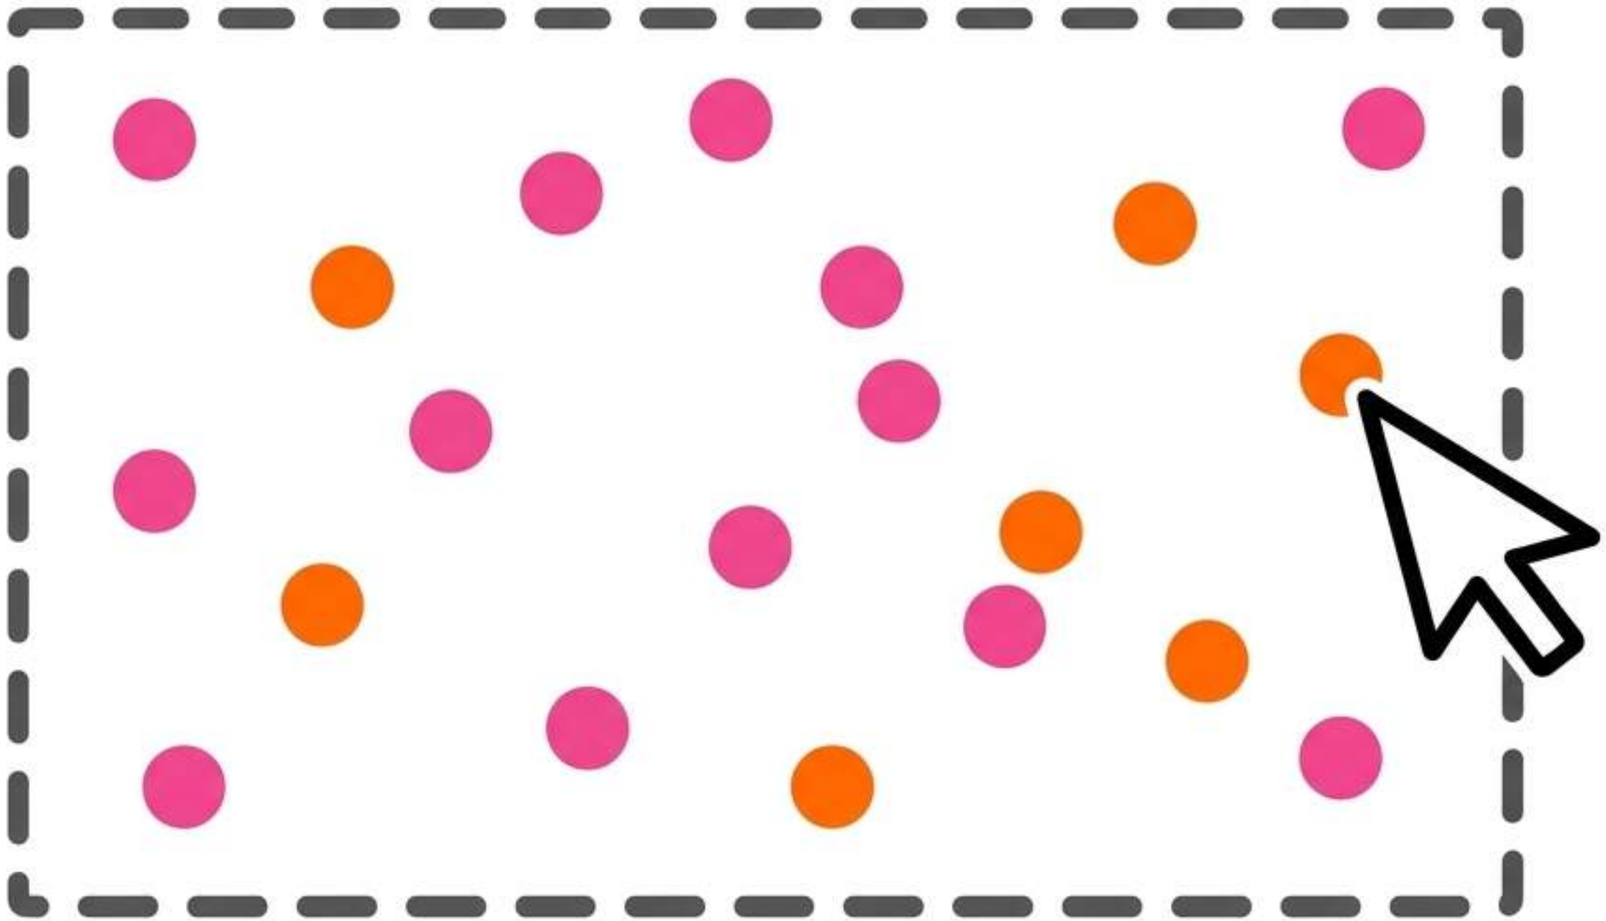


Evaluación final imparcial. Intocable hasta el fin del proyecto.

Gemini Notebook

Búsqueda de Hiperparámetros (Random Search)

Profundidad, Regularización, Learning Rate



Random Search muestrea combinaciones óptimas de manera aleatoria.

Permite explorar un vasto espacio de configuraciones maximizando la eficiencia frente a un presupuesto fijo de tiempo y cómputo.

Gemini Notebook

Anti-Patrones Críticos y Fuga de Información

03

Gemini Notebook

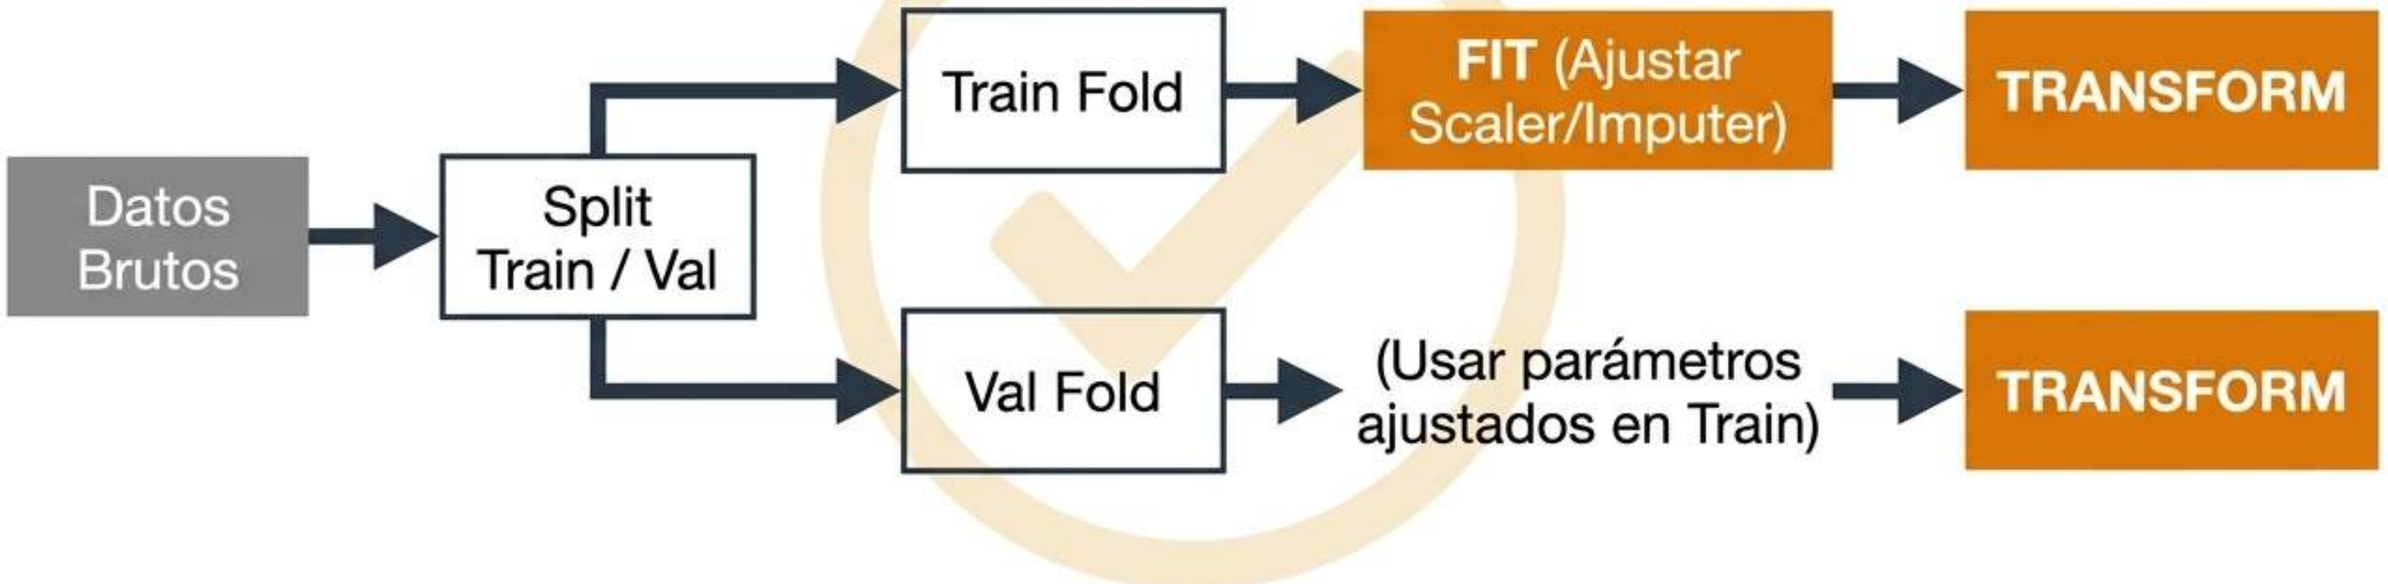
Coder Tips

Cuidado con el **Data Leakage (Fuga de Información).** Ocurre cuando información del set de validación se filtra al modelo durante el entrenamiento.

> ***"Un modelo con fuga de datos en validación es como un estudiante que robó las respuestas del examen final... sacará un 10 en la prueba, pero fallará catastróficamente en el mundo real."***

Gemini Notebook

El Protocolo Sin Sesgo (Pipeline Correcto)



¡La función FIT JAMÁS debe tocar el fold de validación!

Gemini Notebook

Equilibra las fuerzas.
Identifica la tensión entre el Bias y la Vari Varianza para evitar memorizar ruido.

Protege el futuro.
Separa rígidamente tus datos (Train, Dev) y mantén el Test y Set (Holdout) bajo llave.

Cuidado con la fuga.
Aplica el Fit exclusivamente en datos de entrenamiento para evitar el Data Leakage.

Gemini Notebook

¡Gracias por estudiar con nosotros!

Copyright © 2026 Coderhouse. Todos los derechos reservados. Material confidencial.

Gemini Notebook