Machine Learning Avanzado

La Alianza de los Modelos

De algoritmos solitarios a equipos imparables: Entendiendo Bagging, Boosting y Stacking.

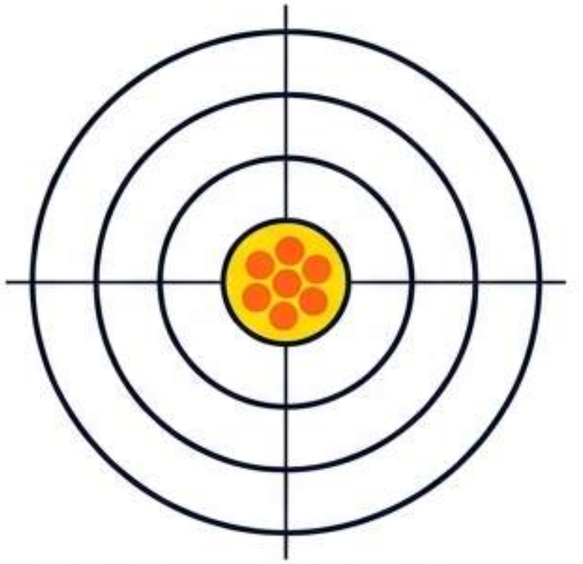
Coderhouse Data Science



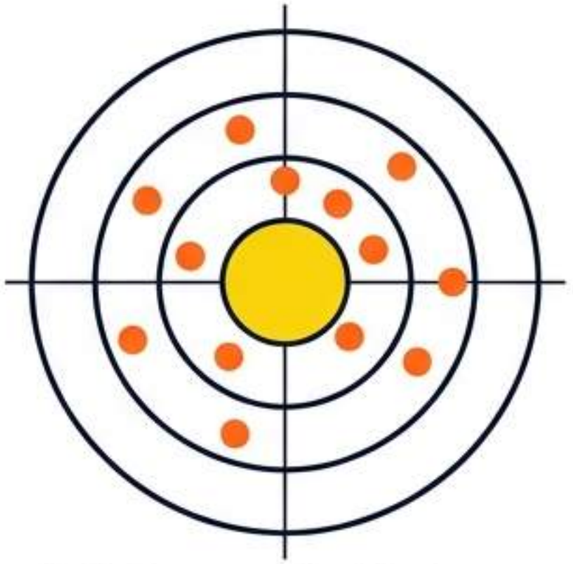
El límite anatómico de un modelo individual

Todo modelo individual se enfrenta a la misma Ecuación del Error:
Error = Sesgo^2 + Varianza + Ruido

- **Sesgo alto (Underfitting):** El modelo es demasiado simple. No entiende el problema.
- **Varianza alta (Overfitting):** El modelo memoriza los datos. Cambia drásticamente ante variaciones minúsculas.
- **Error irreduclible:** El ruido caótico de la vida real.



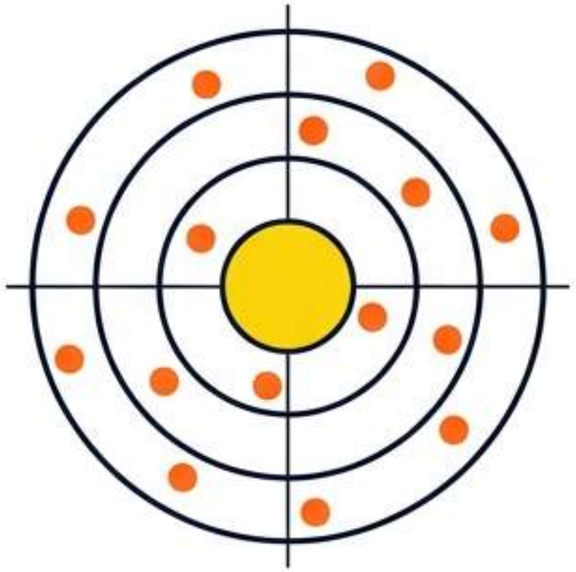
Bajo Sesgo, Baja Varianza



Bajo Sesgo, Alta Varianza



Alto Sesgo, Baja Varianza



Alto Sesgo, Alta Varianza

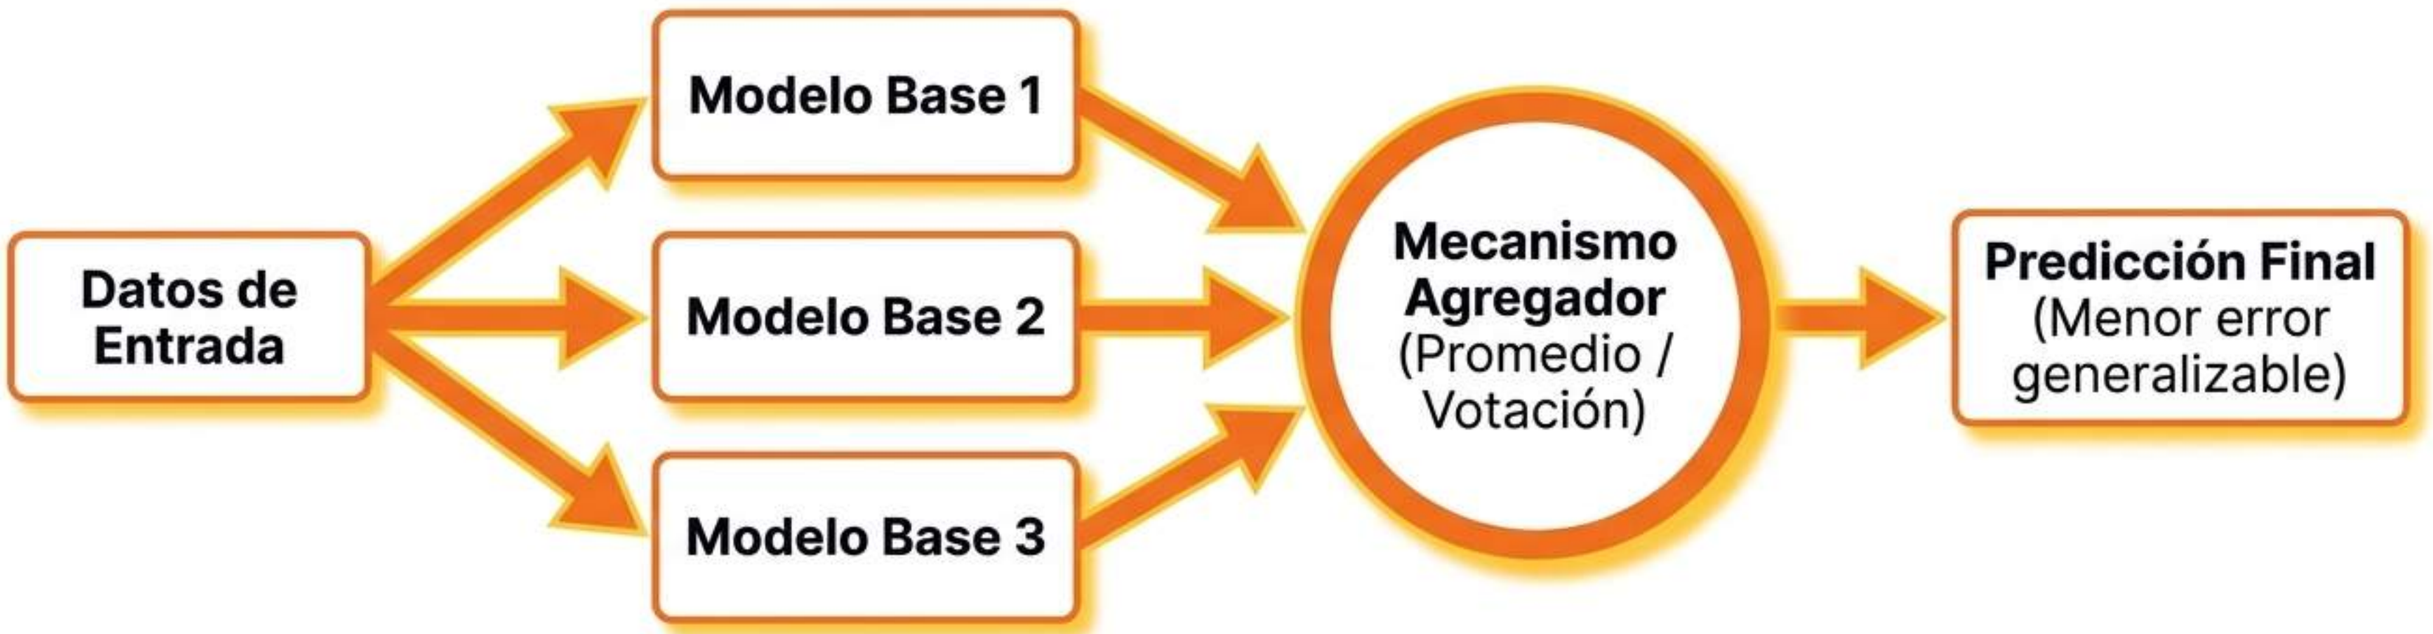
Gemini Notebook

La Sabiduría de las Multitudes

Un ensamble es una arquitectura de decisión distribuida. Múltiples modelos combinan sus señales para cancelar sus errores individuales.

Para que funcione, los modelos deben ser **precisos** (mejores que el azar) y **diversos** (equivocarse en cosas distintas).

Anatomía de un Ensamble



Gemini Notebook

Las tres filosofías de trabajo en equipo



Bagging

Modelos independientes en paralelo. Su objetivo principal es reducir la varianza (estabilizar).



Boosting

Modelos secuenciales donde cada uno corrige los errores del anterior. Su objetivo es reducir el sesgo.



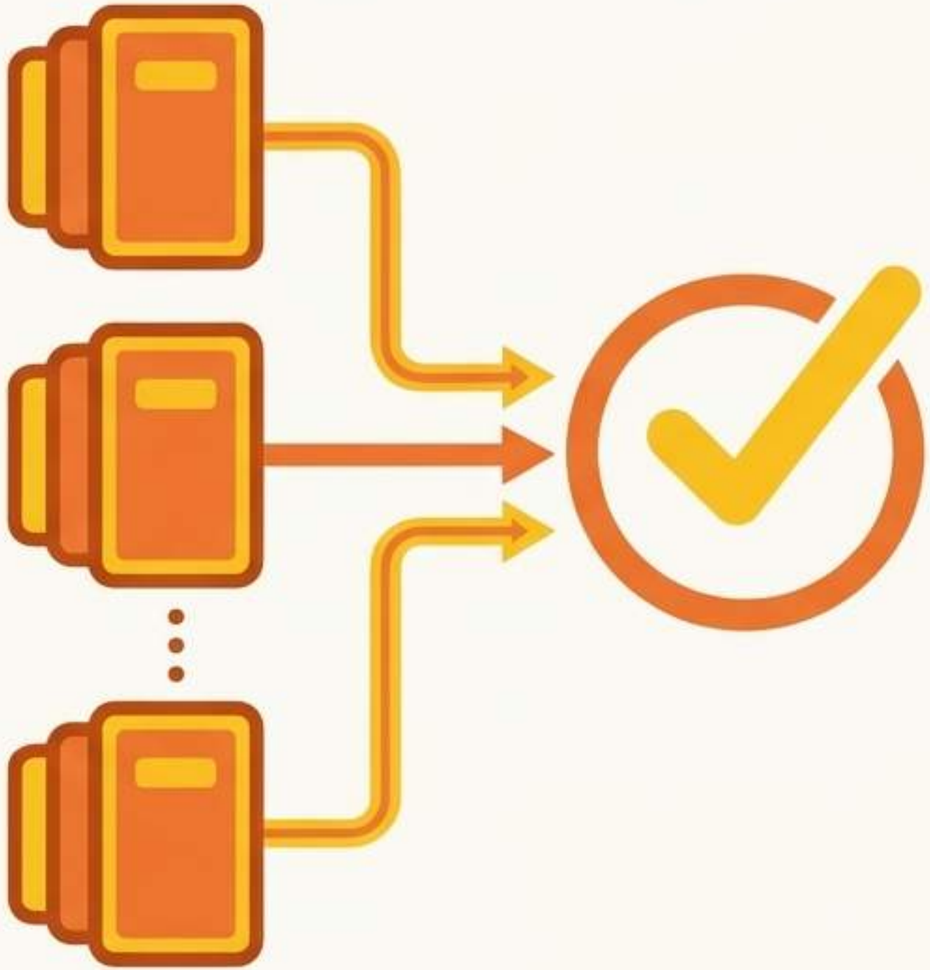
Stacking

Modelos heterogéneos liderados por un meta-modelo que aprende a combinarlos.

Gemini Notebook

Bagging: El equipo en paralelo

Consiste en entrenar múltiples versiones del mismo modelo usando **diferentes sub-muestras aleatorias** de los datos (Bootstrap). Al final, todas las voces tienen el mismo peso.



Variantes principales:

Random Forest: El todoterreno. Robusto, paralelizable y excelente desempeño base.

Extra Trees: Aún más aleatoriedad. Más rápido de entrenar, ideal para datasets gigantescos.

Gemini Notebook

Boosting: La corrección secuencial

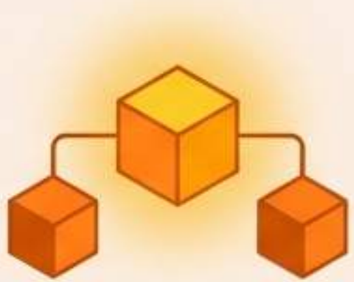
Se construye un modelo aditivo. Cada nuevo modelo (weak learner) se enfoca exclusivamente en aprender los patrones que el ensamble anterior clasificó mal.



Peligro: Al enfocarse tanto en los errores, el Boosting es altamente sensible al ruido y a los outliers.

Gemini Notebook

El Arsenal del Boosting



AdaBoost

Aumenta el peso de las instancias mal clasificadas. Conceptualmente simple. Útil con stumps y datos limpios.



Gradient Boosting

Aprende a predecir el pseudo-residuo (el gradiente negativo de error). Excelente con datos tabulares. Requiere calibración fina.



LightGBM

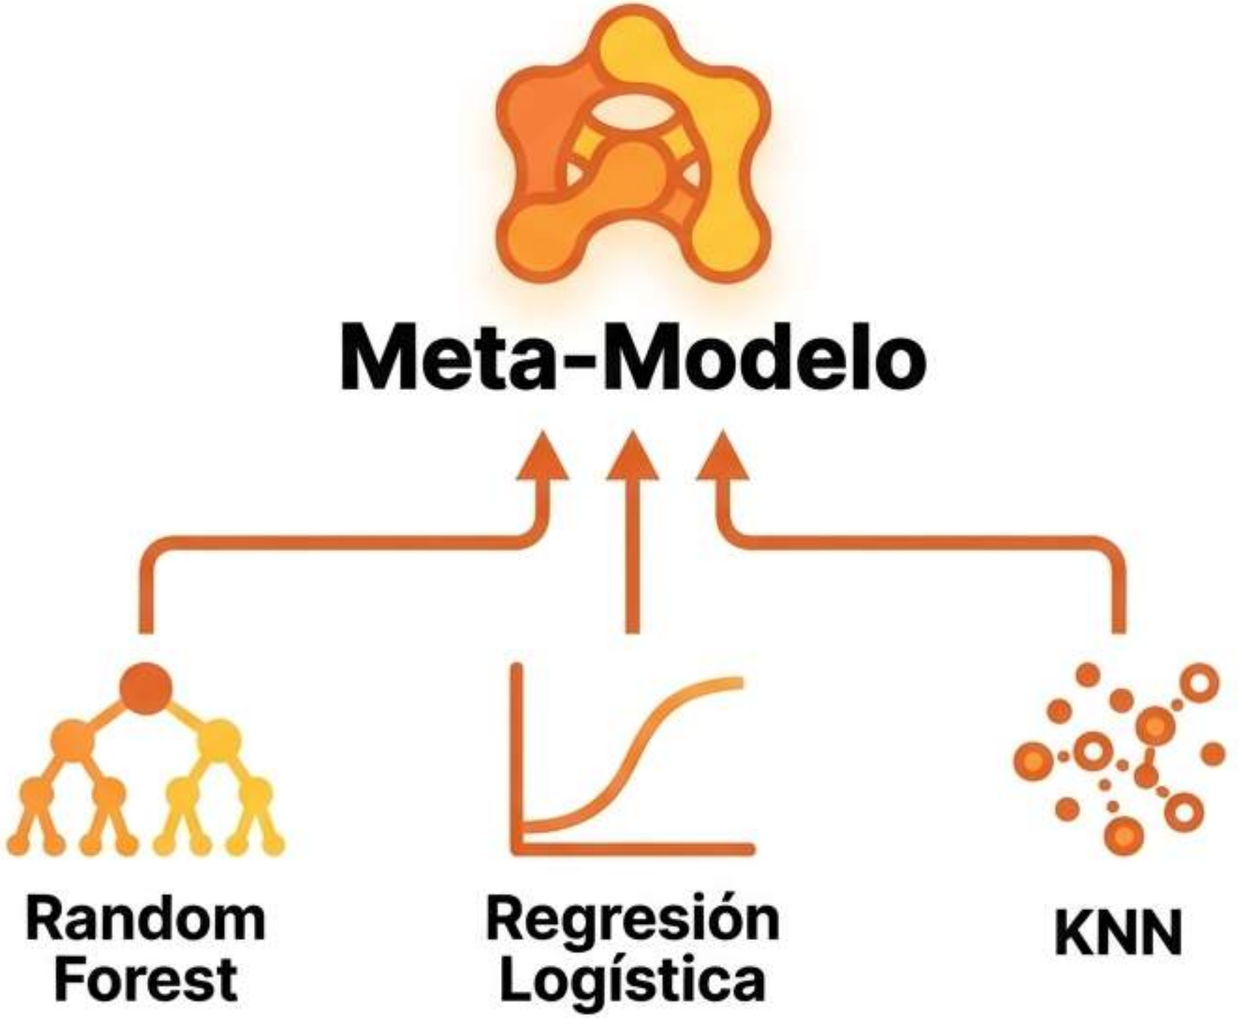
Crecimiento por hoja (leaf-wise) extremadamente rápido y eficiente en memoria. El rey para Big Data, pero tiende a sobreajustar en datasets pequeños.

Gemini Notebook

Stacking: La jerarquía de expertos

En lugar de usar modelos idénticos, usamos familias distintas (ej. un Random Forest, una Regresión Logística y un KNN).

Luego, un Meta-Modelo aprende cuál de ellos tiene la razón en diferentes escenarios.



Tip Práctico: Mantén el meta-modelo simple (una regresión lineal suele bastar) para evitar sobreajuste masivo.

Gemini Notebook

La Matriz de los 3 Titanes

Ensamble	Mecanismo Central	Superpoder	Kriptonita
Bagging	Paralelo (Bootstrap)	Reduce Varianza (Estabilidad)	No mejora modelos de alto sesgo.
Boosting	Secuencial (Corrección)	Reduce Sesgo (Alto poder predictivo)	Sensible al ruido (Overfitting fácil).
Stacking	Jerárquico (Meta-modelo)	Aprovecha fortalezas de algoritmos muy distintos	Complejidad altísima y riesgo de Data Leakage.

Gemini Notebook

El Termómetro de la Regularización

Cómo frenar el sobreajuste penalizando la complejidad del modelo.



Eliminación. Puede llevar coeficientes exactamente a cero. Ideal para seleccionar variables.

El punto medio perfecto. Combina L1 y L2.

Suavización. Encoge los coeficientes pero no los anula. Ideal para alta multicolinealidad.

⚠ **¡Regla de oro!** Siempre debes estandarizar tus variables numéricas antes de regularizar.

Gemini Notebook

Coder Tips

Momentos de la Clase:

El peligro mortal del Data Leakage en Stacking.

Si entrenas tu meta-modelo con las mismas predicciones que los modelos base usaron para aprender, el meta-modelo hará trampa. Para evitarlo, usa estrictamente predicciones Out-of-Fold (OOF) mediante Validación Cruzada.

Gemini Notebook

Momentos de la Clase: Para recordar

Reglas de la Industria para Ensambles

1. **Ten siempre un Baseline**: Empieza con un modelo simple. Solo pasa a un ensamble si la ganancia de métrica justifica el costo computacional.

2. **Test es sagrado**: Nunca optimices hiperparámetros usando tu conjunto de prueba.

3. **Mezcla ponderada**: A veces, promediar a mano dos modelos buenos (Blending) te da 80% de los beneficios del Stacking con el 10% del esfuerzo.



Gemini Notebook

CODERHOUSE

¡Muchas gracias!

Sigan construyendo la alianza.

Copyright © 2026 Coderhouse. All rights reserved. Coderhouse and the Coderhouse logo are trademarks or registered trademarks of Coderhouse.
in the U.S. and/or other countries. All other trademarks are the property of their respective owners.

Gemini Notebook